Homework 1.

Analytical performance model of a small CNN

Необходимо задать 4 математические функции, которые зависят от размера S и разрядности B: FLOPs(S,B), Memory(S,B), Latency(S,B,Θ), Energy(S,B,Θ).

1. Условия и допущения:

padding = k//2, bias = False, ReLU is inplace = True

1 multiply-accumulate = 2 FLOPs

"Memory-limited layers": Pooling и Activations - слои, которые "почти не считают в арифметике".

FLOPs для MaxPool, ReLU, GAP будем считать равными 0.

FP32 = 4 байта на число

ReLU после каждой свёртки

Предполагаем, что Latency и Energy - линейные комбинации FLOPs и Bytes_Moved.

При расчете Bytes_Moved не учитывали кэширование GPU.

Для операций MaxPool, ReLU, GlobalAvgPool обучаемые веса отсутствуют.

Параметры $\Theta_{1,2,3}$ и $\alpha_{1,2,3}$. ($\Theta=(\Theta_1,\Theta_2,\Theta_3)$; $\alpha=(\alpha_1,\alpha_2,\alpha_3)$) - это набор калиброванных параметров для Latency и Energy соответственно. Θ_3 и α_3 - фиксированные аппаратные и программные накладные расходы, которые не зависят от S и B.

Модель:

Conv 7×7 S2 3→32 + ~~ReLU~~, MaxPool 3×3 S2 P1
Conv 5×5 32 → 64 + ReLU
Conv 3×3 S2 64 → 128 + ReLU
Conv 1×1 128 → 256 + ReLU
Conv 3×3 S2 256 → 256 + ReLU
Conv 1×1 256 → 512 + ReLU
head: GlobalAvgPool, Linear 512→256, ReLU, Linear 256→100

2. Последовательный вывод формулы

На примере Conv 7×7: проходимся по картинке окошком 7×7, 3 канала RGB → получаем $7 \times 7 \times 3 = 147$ чисел.

S2 – stride = 2 (сдвиг на 2 пикселя)

Перейдём к расчёту:

- Conv 7×7 S2 3 → 32 + ReLU, MaxPool 3×3 S2 p1

На вход подаётся $(B, 3, S, S)$; padding = 7//2 = 3

$$S_{out} = \left[\frac{S_{in} + 2\,padding - kernel}{stride}\right] + 1 = \left[\frac{S + 2 \cdot 3 - 7}{2}\right] + 1 =$$

$$= \frac{S}{2}$$ (S чётное и кратное 16: Images sizes are square H = W = S, always a multiple of 16)

Получаем тензор формы $(B, 32, S/2, S/2)$

После ReLU размерность не меняется

MaxPool 3×3 S2 p1

$$S_{out} = \left[\frac{S/2 + 2 \cdot 1 - 3}{2}\right] + 1 = \frac{S}{4}$$

Получаем $(B, 32, S/4, S/4)$

FLOPs:

$7 \times 7 \times 3 \times 2 = 294$ FLOPs на пиксель

1 MAC = 2 FLOPs

На входе картинка $(S/2) \times (S/2) \Rightarrow 294 \times \frac{S}{2} \times \frac{S}{2} \times 32 =$ (32 выходн. канала)

$$= 2352 \times S^2 \text{ FLOPs}$$

Весь батч B: $FLOPs = 2352 \times S^2 \times B$

Как и договаривались FLOPs для ReLU, MaxPool считаем 0.

Memory: $7 \times 7 \times 3 \times 32 \times 4$ байта $= 4 \times 4704$ байт – веса

Активации:

входной $B \times 3 \times S \times S = 3S^2B$

выход Conv и ReLU: $B \times 32 \times \frac{S}{2} \times \frac{S}{2} = 8BS^2$

выход MaxPool: $B \times 32 \times \frac{S}{4} \times \frac{S}{4} = 2BS^2$

Пулинг Memory = 4×(3S²B + 8S²B + 2S²B + 4704) =

= 52S²B + 18816 = 4×(13S²B + 4704)

Bytes_Moved:

Conv 7×7 вход 3S²B

выход 8S²B

веса 4704

4×(3S²B + 8S²B + 4704) = 4×(11S²B + 4704)

ReLU: вход 8BS²

выход 8S²B (inplace, но операция происходит в памяти)

4×(8S²B + 8S²B) = 4×(16S²B)

MaxPool вход 8S²B

выход 2S²B

4×(8S²B + 2S²B) = 4×(10S²B)

Итого Bytes_Moved = 4×(37S²B + 4704) байт

- Conv 5×5 32 → 64 + ReLU 5//2 = 2

$S_{out} = \left[\frac{S/4 + 2\cdot 2 - 5}{1}\right] + 1 = S/4$

(B, 64, S/4, S/4) - получили, на вход было (B, 32, S/4, S/4)

FLOPs = 5×5×32×2×64×S/4×S/4 = 6400S²B

Memory: веса = 5×5×32×64 = 51200

активации: входной Bx32x S/4 x S/4

выходной Bx64x S/4 x S/4

Memory = 4×(2S²B + 4S²B + 51200) = 4×(6S²B + 51200)

Bytes_Moved:

Conv 5×5 вход 2S²B

выход 4S²B

веса 51200

4×(6S²B + 51200)

ReLU вход $4S^2B$

выход $4S^2B$

$4 \times (8S^2B)$

Bytes_Moved = $4 \times (14S^2B + 51200)$ байт

- Conv 3×3 S2 64 → 128 3//2 = 1

на вход (B, 64, S/4, S/4)

$S_{out} = \left[\frac{S/4 + 2 \cdot 1 - 3}{2}\right] + 1 = \frac{S}{8}$

получаем (B, 128, S/8, S/8)

FLOPs = $3 \times 3 \times 64 \times 2 \times \frac{S}{8} \times \frac{S}{8} \times 128 \times B = 2304\,S^2B$

Memory: веса = $3 \times 3 \times 64 \times 128 = 73728$

активации:

входной $B \times 64 \times S/4 \times S/4$

выходной $B \times 128 \times S/8 \times S/8$

Memory = $4 \times (6S^2B + 73728)$ байт

Bytes_Moved:

Conv 3×3 вход $4S^2B$

выход $2S^2B$

веса 73728

$4 \times (6S^2B + 73728)$

ReLU вход $2S^2B$

выход $2S^2B$

$4 \times (4S^2B)$

Bytes_Moved = $4 \times (10S^2B + 73728)$ байт

- Conv 1×1 128 → 256 + ReLU 1//2 = 0

на вход (B, 128, S/8, S/8)

$S_{out} = \left[\frac{S/8 + 2 \cdot 0 - 1}{1}\right] + 1 = S/8$

получаем (B, 256, S/8, S/8)

FLOPs = $1\times1\times128\times2\times \frac{S}{8}\times\frac{S}{8}\times256\times B = 1024\,S^2B$

Memory: веса $= 1\times1\times128\times256 = 32\,768$

активации:

входной $B\times128\times\frac{S}{8}\times\frac{S}{8}$

выходной $B\times256\times\frac{S}{8}\times\frac{S}{8}$

Memory $= 4\times(6\,S^2B + 32\,768)$ байт

Bytes_Moved:

Conv 1×1 вход $2\,S^2B$

выход $4\,S^2B$

веса $32\,768$

$4\times(6\,S^2B + 32\,768)$

ReLU вход $4\,S^2B$

выход $4\,S^2B$

$4\times(8\,S^2B)$

Bytes_Moved $= 4\times(14\,S^2B + 32\,768)$ байт

- Conv 3×3 S2 256 → 256 + ReLU $3//2 = 1$

на вход $(B; 256, \frac{S}{8}, \frac{S}{8})$

$S_{out} = \left[\frac{\frac{S}{8}+2\cdot1-3}{2}\right]+1 = \frac{S}{16}$

получаем $(B, 256, \frac{S}{16}, \frac{S}{16})$

FLOPs $= 3\times3\times256\times2\times\frac{S}{16}\times\frac{S}{16}\times256\times B = 4608\,S^2B$

Memory: веса $= 3\times3\times256\times256 = 589\,824$

активации:

входной $B\times256\times\frac{S}{8}\times\frac{S}{8}$

выходной $B\times256\times\frac{S}{16}\times\frac{S}{16}$

Memory $= 4\times(5\,S^2B + 589\,824)$

Bytes_Moved:

Conv 3×3 вход $4\,S^2B$

выход $1\,S^2B$ веса $589\,824$

$4 \times (5 S^2 B + 589\,824)$

ReLU вход $1 S^2 B$

выход $1 S^2 B$

$4 \times (2 S^2 B)$

Bytes_Moved = $4 \times (7 S^2 B + 589\,824)$ байт

- Conv 1×1 256 → 512 + ReLU $1 \cdot 1^2 = 0$

на вход $(B, 256, S/16, S/16)$

$S_{вых} = \left[\frac{S/16 + 2 \cdot 0 - 1}{1}\right] + 1 = S/16$

получаем $(B, 512, S/16, S/16)$

FLOPs = $1 \times 1 \times 256 \times 2 \times \frac{S}{16} \times \frac{S}{16} \times 512\ B = 1024\ S^2 B$

Memory: веса = $1 \times 1 \times 256 \times 512 = 131\,072$

активации: входной $B \times 256 \times S/16 \times S/16$

выходной $B \times 512 \times S/16 \times S/16$

Memory = $4 \times (3 S^2 B + 131\,072)$ байт

Bytes_Moved: Conv 1×1 вход $S^2 B$

выход $2 S^2 B$

веса 131072

$4 \times (3 S^2 B + 131\,072)$

ReLU вход $2 S^2 B$

выход $2 S^2 B$

$4 \times (4 S^2 B)$

Bytes_Moved = $4 \times (7 S^2 B + 131\,072)$ байт

- head: GlobalAvgPool, Linear 512 → 256, ReLU, Linear 256 → 100

на вход получаем $(B, 512, S/16, S/16)$

GlobalAvgPool работает со всей пространственной сеткой сразу. После GAP пространственные размерности исчезают. На выходе получаем $(B, 512)$

FLOPs для GAP мы примем равным нулю

Linear 512 → 256

на входе вектор из 512 чисел (B, 512)

FLOPs = 512 × 256 × 2 × B = 262 144 B

ReLu: размерность не меняет; FLOPs = 0

Linear 256 → 100:

на вход (B, 256)

на выход (B, 100)

FLOPs = 256 × 100 × 2 × B = 51 200 B

Итого FLOPs = 262 144 B + 51 200 B = 313 344 B

Memory:

GAP входной тензор $B \times 512 \times \frac{S}{16} \times \frac{S}{16} = 2S^2B$

выходной $B \times 512$

$4 \times (2S^2B + 512B)$

Linear 512-256

входной 512 B

выходной 256 B

веса = 512 × 256 = 131 072

$4 \times (768B + 131\,072)$

ReLU

входной 256 B

выходной 256 B

$Memory_{ReLU} = 0$

Linear 256 → 100 веса = 256 × 100 = 25 600

входной 256B

выходной 100B

$4 \times (356B + 25600)$

Bytes_Moved:

GAP $2xog$ $2S^2B$

$bxog$ $512B$

$4 \times (2S^2B + 512B)$

Linear $511 \to 256$

$bxog$ $512B$

$boxog$ $256B$ $bea = 131072$

$4 \times (768B + 131072)$

ReLU

$bxog$ $256B$

$boxog$ $256B$

$4 \times (512B)$

Linear $256 \to 100$

$bxog$ $256B$ $bea = 25600$

$boxog$ $100B$

$4 \times (356B + 25600)$

3. Подсчёт итоговой формулы

$FLOPs = 2352S^2B + 6400S^2B + 2304S^2B + 1024S^2B +$

$+ 4608S^2B + 1024S^2B + 262144B + 51200B = \underline{17712S^2B + 313344B}$

Для Memory расчёт иной, потому что вход следующего блока – выход предыдущего. Считаем не итоговое решение, а каждый умножитель тензор один раз:

$Memory = 4 \times (3BS^2 + 8BS^2 + 2BS^2 + 4S^2B + 2S^2B + 4S^2B + 1S^2B +$

$+ 2S^2B + 512B + 256B + 100B + 1039968) =$

$= 4 \times (26S^2B + 868B + 1039968)$

$$Bytes_Moved = 4 \times (37S^2B + 4704 + 14S^2B + 51200 + 10S^2B + 73728 + 14S^2B + 32768 + 7S^2B + 589824 + 7S^2B + 131072 + 2S^2B + 512B + 768B + 131072 + 512B + 356B + 25600) = 4 \times (91S^2B + 2148B + 1039968)$$

Итого:

$$FLOPs(S,B) = (17712S^2 + 313344)B$$

$$Memory(S,B) = 4 \times (26S^2B + 868B + 1039968)$$

$$Bytes_Moved(S,B) = 4 \times (91S^2B + 2148B + 1039968)$$

$$Latency(S,B,\Theta) = \Theta_1 \times FLOPs(S,B) + \Theta_2 \times Bytes_Moved(S,B) + \Theta_3$$

$$Energy(S,B,\alpha) = \alpha_1 \times FLOPs(S,B) + \alpha_2 \times Bytes_Moved(S,B) + \alpha_3$$

Подставим $FLOPs(S,B)$ и $Bytes_Moved(S,B)$:

$$Latency(S,B,\Theta) = \Theta_1 \times B \times (17712S^2 + 313344) + \Theta_2 \times (364S^2B + 8592B + 4159872) + \Theta_3$$

$$Energy(S,B,\alpha) = \alpha_1 \times B \times (17712S^2 + 313344) + \alpha_2 \times (364S^2B + 8592B + 4159872) + \alpha_3$$