Содержание

Воспроизведение метода Selection via Proxy для отбора обучающих данных 1
Аннотация . . . 1
1. Постановка задачи . . . 1
2. Метод . . . 2
2.1. Общая схема . . . 2
2.2. Использованные критерии . . . 2
2.3. Данные Amazon и адаптация метода . . . 2
2.4. Условия и ограничения воспроизводимости . . . 3
3. Результаты . . . 3
3.1. CIFAR-10: критерий отбора и размер подвыборки . . . 3
3.2. CIFAR-100: сравнение proxy-архитектур и корреляция Спирмена . . . 4
3.3. CIFAR-100: влияние длительности обучения proxy . . . 5
3.4. Amazon: классификация товаров по подготовленным признакам . . . 6
4. Обсуждение . . . 8
4.1. Что удалось проверить . . . 8
4.2. Почему важен выбор целевой модели . . . 8
4.3. Ограничения . . . 8
5. Заключение . . . 9
Литература . . . 9

Воспроизведение метода Selection via Proxy для отбора обучающих данных

Курс: Deep Learning / Homework 2
Статья: Cody Coleman et al., Selection via Proxy: Efficient Data Selection for Deep Learning, ICLR 2020
Код экспериментов: AITH_Efficient_NN / hw2
Оригинальная реализация авторов статьи: selection-via-proxy

Аннотация

В работе исследуется подход Selection via Proxy (SVP): вместо обучения целевой модели на всём наборе данных сначала обучается более дешёвая proxy-модель, с помощью которой оцениваются обучающие примеры. Затем по этим оценкам выбирается подмножество данных, на котором обучается целевая модель. Цель экспериментов — проверить, насколько сильно можно сократить обучающую выборку, сохранив качество, и как на результат влияют критерий отбора и длительность обучения proxy-модели.

Эксперименты проведены на CIFAR-10, CIFAR-100 и данных о товарах и отзывах Amazon. На CIFAR-10 методы на основе оценок модели показали более высокую точность, чем случайный отбор при нескольких сравнимых бюджетах. На CIFAR-100 увеличение обучения proxy с 25 до 100 эпох подняло точность целевой модели с 71,60% до 72,56%, но увеличило общее время примерно с 105,8 до 119,8 минуты. В Amazon-эксперименте SVP при отборе 50% данных приблизился к результату обучения на полном наборе. При бюджете 20% исходный вариант SVP заметно уступил случайному отбору; дополнительная фильтрация примеров с бесконечным числом forgetting events улучшила метрики, хотя сравнение требует осторожности из-за различий в сохранённых конфигурациях. Результаты в основном получены в одиночных запусках, поэтому их следует считать наблюдениями для исследованных конфигураций, а не статистически подтверждёнными оценками.

1. Постановка задачи

Обучение нейронной сети на всём наборе данных может быть дорогим, особенно если модель большая, а обучающих примеров много. При этом часть примеров может быть избыточной для достижения сопоставимого качества. SVP предлагает использовать небольшую proxy-модель для ранжирования данных, выбрать ограниченную часть обучающей выборки и обучить целевую модель уже на ней.

В этой работе проверялись следующие вопросы:

1. Может ли отбор по оценкам proxy-модели дать качество выше случайного отбора при одинаковом размере подвыборки?
2. Как меняются точность и полное время работы, если обучать proxy-модель разное число эпох?
3. Насколько согласованно разные архитектуры ранжируют обучающие примеры?
4. Можно ли применить идею отбора не только к изображениям, но и к признакам товаров и отзывов Amazon?
5. Улучшится ли результат при небольшом бюджете, если отдельно обработать примеры, которые proxy-модель так и не научилась классифицировать правильно?

Это воспроизведение отдельных идей и экспериментов статьи с адаптацией к доступному коду, данным и вычислительным условиям. Оно не является полным повторением всех экспериментов оригинальной публикации.

2. Метод

2.1. Общая схема

Эксперимент состоит из трёх этапов:

1. Обучение proxy-модели. Во время обучения собираются оценки, связанные с тем, насколько легко или трудно классифицировать каждый пример.
2. Отбор подмножества. Примеры ранжируются по выбранному критерию, после чего сохраняется заданная доля обучающих данных.
3. Обучение целевой модели. Целевая архитектура обучается на выбранном подмножестве и оценивается на тестовой выборке.

Для корректной оценки эффективности нужно учитывать все этапы:

$$T_{\mathrm{SVP}} = T_{\mathrm{proxy}} + T_{\mathrm{selection}} + T_{\mathrm{target}}.$$

Время самого отбора может быть очень небольшим, но обучение proxy тоже требует вычислений. Поэтому ускорение обучения целевой модели ещё не означает ускорения всего процесса.

2.2. Использованные критерии

На CIFAR-10 сравнивались случайный отбор (Random), отбор по forgetting events и отбор по энтропии предсказаний (Entropy). Forgetting events отражают случаи, когда пример, ранее классифицированный правильно, снова становится классифицированным неправильно в процессе обучения. Энтропия предсказаний используется как мера неопределённости модели.

Для экспериментов с CIFAR использовалась связка из относительно компактной proxy-модели PreActResNet-20 и более мощной целевой модели WideResNet-28-10. Такой выбор был сделан намеренно: хотелось проверить, работает ли отбор, когда proxy и target отличаются не только размером, но и архитектурой, а целевая модель обладает существенно большей ёмкостью. В переписке по разработке WideResNet-28-10 выбиралась как сильная CIFAR-архитектура, позволяющая проверить, сохраняется ли полезность отобранного подмножества для модели, способной извлекать более сложные закономерности. Это не попытка точно повторить исходную пару архитектур из статьи, а дополнительная проверка переносимости метода на более сильную целевую модель.

2.3. Данные Amazon и адаптация метода

Для Amazon использовался подготовленный ранее в рамках проекта Amazon Audit Service набор данных, а также уже существовавшие датафрейм, pipeline обработки и текстовые эмбеддинги товаров и отзывов. Это позволило проверить идею SVP на другом типе данных, не ограничиваясь стандартными изображениями. Датасет был выбран также потому, что он новее набора, использованного в соответствующем эксперименте оригинальной статьи, и даёт возможность проверить применимость подхода к более современным данным и признакам.

В данной задаче модель предсказывает один из трёх классов: Flop, Stable и Hit. В журнале подготовки признаков зафиксировано 104 признака после обработки. Это не строгая реплика текстовой классификации из оригинальной статьи: здесь используются подготовленные табличные признаки, в том числе эмбеддинги текста и отзывов. Поэтому Amazon-эксперимент следует рассматривать как адаптацию идеи SVP к существующему прикладному pipeline.

В дополнительном варианте SVP для бюджета 20% из отбора исключались примеры с бесконечными оценками forgetting events. Такие значения возникали для примеров, которые proxy-модель не классифицировала правильно в ходе обучения. Этот вариант далее называется SVP 20% + drop-inf. Он дал заметно лучшие метрики, чем исходный SVP 20%, но точное сравнение требует учитывать сохранённые размеры выборок и настройки экспериментов.

2.4. Условия и ограничения воспроизводимости

В доступных логах часто используется seed 42. Для CIFAR-100 в эксперименте длительности proxy было 50 000 обучающих и 10 000 тестовых изображений; на обучение target отбиралось 25 000 примеров, то есть 50% обучающего набора. Целевая модель обучалась 100 эпох.

Нет свидетельств, что все конфигурации повторялись с несколькими независимыми seed. Поэтому ниже приводятся наблюдаемые значения отдельных запусков без доверительных интервалов. Быстрые предварительные прогоны CIFAR-10 на 30 эпох не смешиваются с более длинными запусками на 200 эпох.

3. Результаты

3.1. CIFAR-10: критерий отбора и размер подвыборки

В таблице приведены длинные запуски с расписанием обучения целевой модели на 200 эпох. В архиве есть результаты Random для бюджетов 30%, 50% и 100%; forgetting events для 30%, 50% и 70%; Entropy — только для 50%. Отсутствующие комбинации не восстанавливались интерполяцией.

Метод отбора	Доля данных	Точность на тесте	Время proxy, с	Время target, с	Полное время, мин (прибл.)
Random	30%	90,57%	0,0	8 939,5	149,0
Forgetting events	30%	92,79%	790,7	8 973,9	162,7
Random	50%	93,12%	0,0	13 197,3	220,0
Forgetting events	50%	94,81%	809,9	13 419,4	237,2
Entropy	50%	95,20%	825,9	13 712,0	242,3
Forgetting events	70%	95,00%	1 026,0	18 560,8	326,4
Random	100%	94,96%	0,0	25 097,8	418,3

Рисунок 1. Точность на тесте для фактически выполненных конфигураций CIFAR-10. Точка Entropy показана отдельно, поскольку в архиве есть только один результат для этого метода.

Рисунок 2. Приблизительное полное время: обучение proxy, отбор и обучение target. Для Random отдельного этапа обучения proxy нет.

При бюджете 50% forgetting events достиг 94,81%, тогда как случайный отбор — 93,12%. При бюджете 30% разница составила 92,79% против 90,57%. Лучшее значение среди приведённых запусков — 95,20% у Entropy при бюджете 50%. Оно на 0,24 процентного пункта выше результата Random на полном наборе (94,96%).

Это интересное наблюдение, но не основание утверждать, что уменьшение обучающей выборки само по себе повышает качество. Все результаты получены в отдельных запусках, а разброс между seed не измерялся. Кроме того, единственная точка Entropy не позволяет судить о поведении метода на других

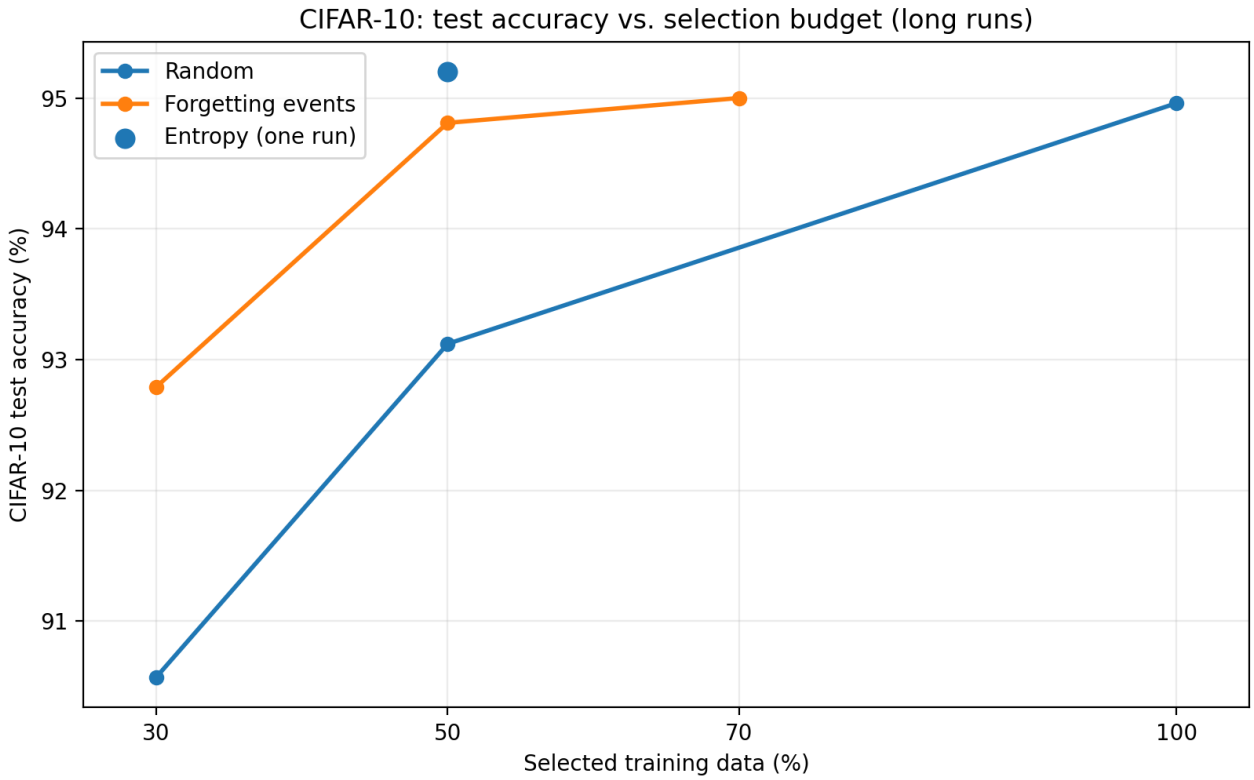


Рис. 1: Точность CIFAR-10 в зависимости от бюджета

бюджетах. Временные значения также показывают, что proxy-обучение добавляет стоимость: при 50% бюджета качество выросло, но полное время оказалось больше, чем у Random 50%.

3.2. CIFAR-100: сравнение proxy-архитектур и корреляция Спирмена

Для сравнения архитектур PreActResNet-20, PreActResNet-56 и PreActResNet-110 каждая модель обучалась 50 эпох на CIFAR-100. Целью было не только сравнить их тестовую точность, но и получить оценки forgetting events и проверить, насколько согласованно архитектуры ранжируют примеры. Для последней задачи планировалось вычислить корреляцию рангов Спирмена между оценками моделей.

Proxy-архитектура	Эпохи	Точность на тесте	Время обучения, с
PreActResNet-20	50	65,43%	811,0
PreActResNet-56	50	64,30%	1 150,4
PreActResNet-110	50	44,42%	1 469,7

В данном запуске PreActResNet-20 показала наибольшую точность и потребовала меньше всего времени. Увеличение глубины не улучшило результат при выбранном расписании обучения; PreActResNet-110 заметно отстала. Это вывод только для конкретной конфигурации: по одному запуску нельзя заключить, что более глубокие модели в целом хуже.

Скрипт дошёл до этапа расчёта матрицы Спирмена, но процесс завершился с ошибкой инициализации OpenMP (libiomp5md.dll была загружена повторно). Надёжная матрица корреляций в предоставленных логах отсутствует. Поэтому численные значения корреляции и вывод о согласованности ранжирований здесь не приводятся. Соответствующий эксперимент нужно повторить после исправления окружения либо получить сохранённый файл с результатами.

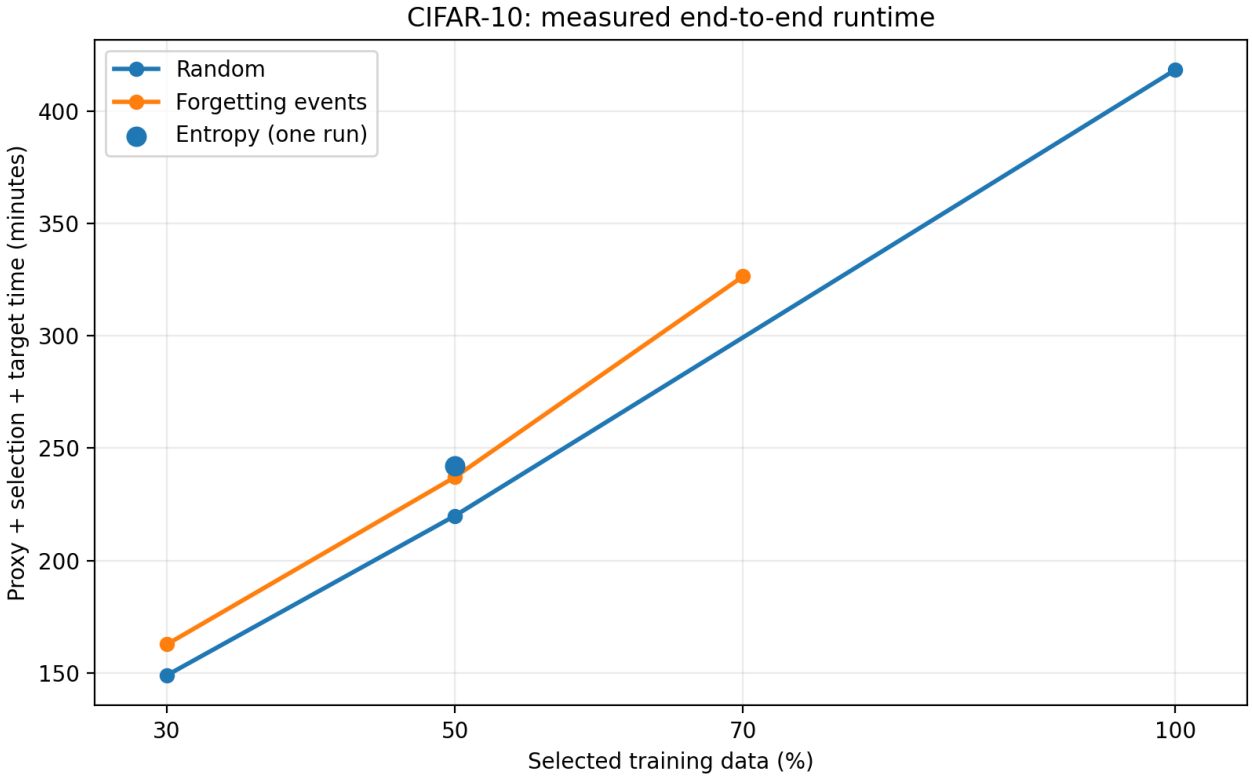
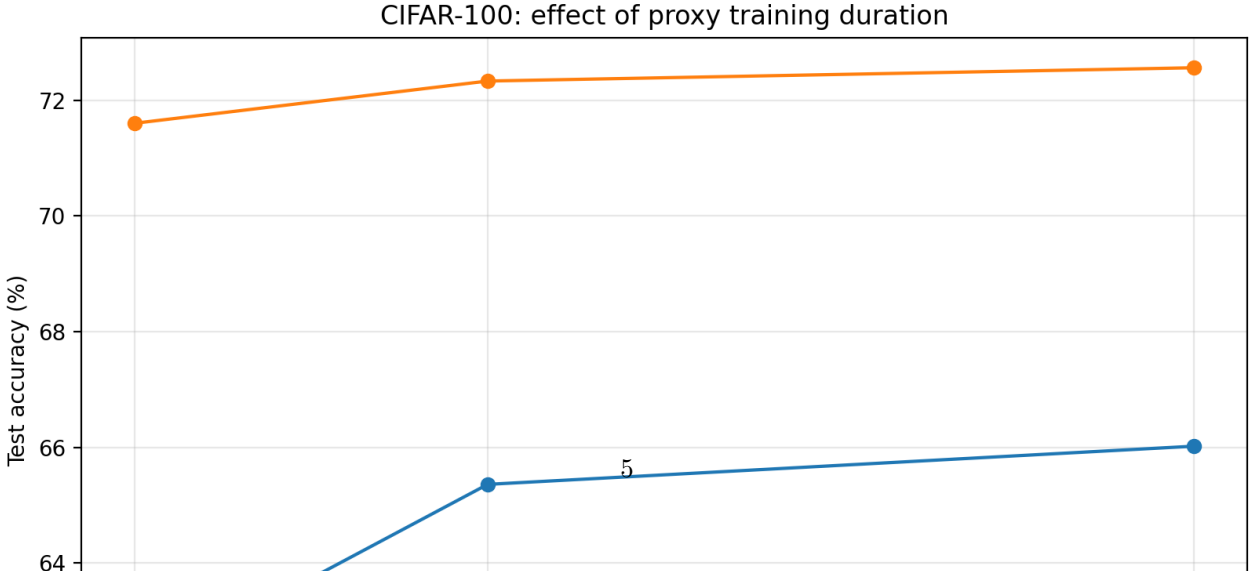


Рис. 2: Время CIFAR-10 в зависимости от бюджета

3.3. CIFAR-100: влияние длительности обучения proxy

В этой серии менялась только длительность обучения proxy: 25, 50 или 100 эпох. Во всех трёх случаях отбиралось 50% обучающего набора (25 000 из 50 000 примеров), а целевая модель обучалась 100 эпох. Использовался seed 42.

Эпохи proxy	Точность proxy	Время proxy, с	Время отбора, с	Точность target	Время target, с	Полное время, мин (прибл.)
25	62,11%	267,9	0,0024	71,60%	6 078,8	105,8
50	65,36%	532,9	0,0022	72,33%	6 075,7	110,1
100	66,02%	1 051,5	0,0023	72,56%	6 136,0	119,8



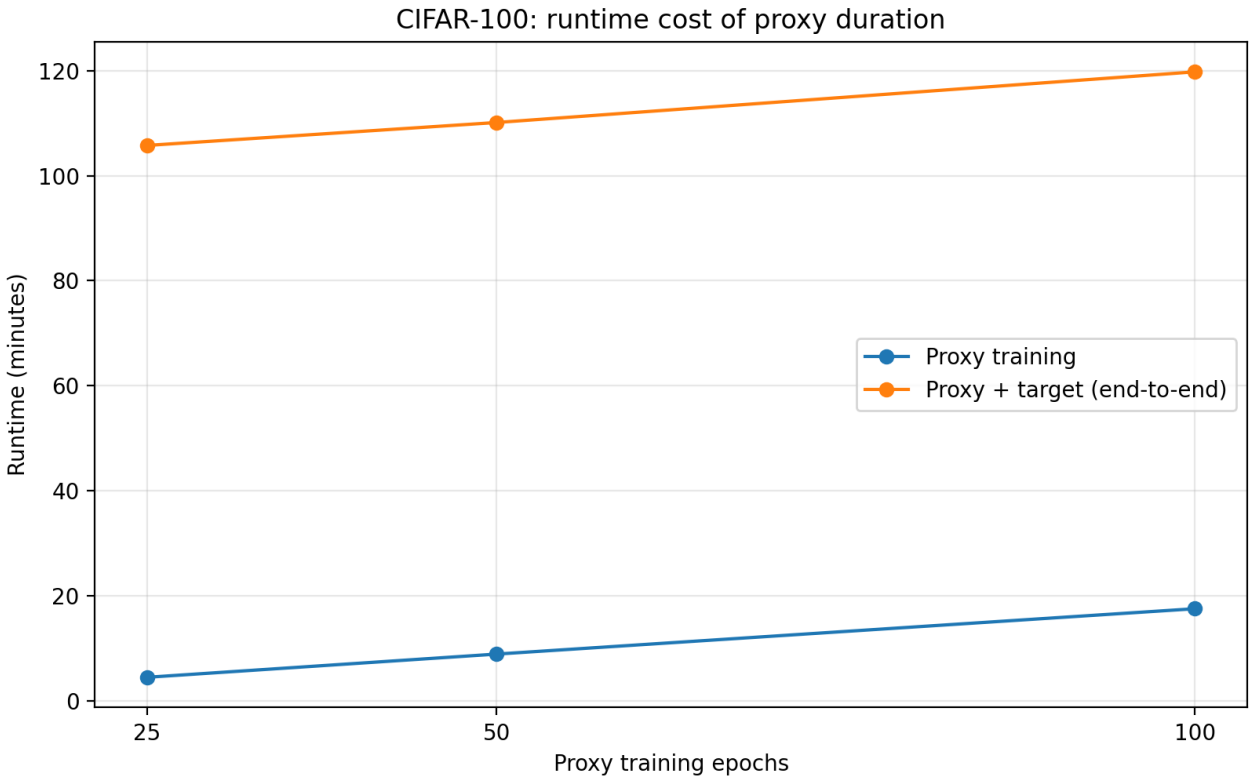


Рис. 4: Время CIFAR-100 в зависимости от длительности proxy

лидирует вариант на 100 эпох. Вариант на 50 эпох занимает промежуточное положение, но имеющихся данных недостаточно, чтобы называть его универсально оптимальным.

В предоставленных логах нет сопоставимого baseline, где target обучена на полном наборе при тех же архитектуре, расписании и аппаратных условиях. Поэтому эта серия показывает компромисс между длительностью proxy и качеством внутри SVP, но не позволяет вычислить ускорение относительно полного обучения.

Команды, которыми запускалась серия, соответствовали следующей схеме:

python cifar/run_spearman.py --workers 2
python cifar/run_partial_training.py --proxy-epochs 25 --fraction 0.5 --target-epochs 100 --workers 2
python cifar/run_partial_training.py --proxy-epochs 50 --fraction 0.5 --target-epochs 100 --workers 2
python cifar/run_partial_training.py --proxy-epochs 100 --fraction 0.5 --target-epochs 100 --workers 2

Запуск run_spearman.py не завершился получением достоверной матрицы, в отличие от трёх запусков run_partial_training.py, для которых итоговые метрики сохранены.

3.4. Amazon: классификация товаров по подготовленным признакам

Amazon-эксперимент использует подготовленный pipeline проекта Amazon Audit Service. В таблице приведены метрики из сохранённого основного сравнения. Macro F1 учитывает качество по всем трём классам, HitRate@5% — отдельную метрику для класса Hit, а Hit F1 — F1 для этого класса.

Вариант	Число обучающих примеров	Доля	Macro F1	HitRate@5%	Hit F1	Время, с
Full	468 003	100%	0,9282	85,42%	0,8346	11 288
Random 20%	93 600	20%	0,9232	84,33%	0,8210	2 352
SVP 20%	93 600	20%	0,8522	67,70%	0,6262	2 364
Random 50%	234 001	50%	0,9232	85,28%	0,8208	5 409
SVP 50%	234 001	50%	0,9254	85,63%	0,8260	4 696

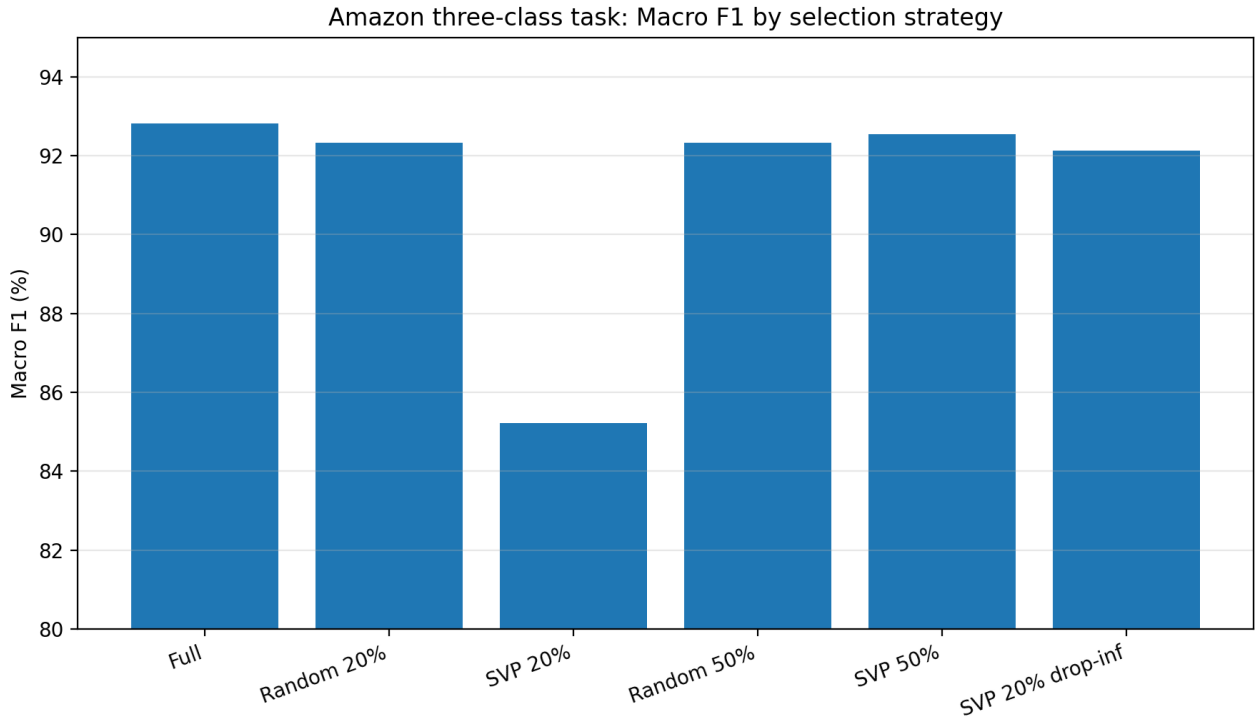


Рис. 5: Сравнение Macro F1 для Amazon

Рисунок 5. Macro F1 для основных вариантов Amazon-эксперимента.

При бюджете 50% SVP достиг Macro F1 = 0,9254 — это близко к результату полного набора (0,9282) и немного выше случайного отбора 50% (0,9232). В сохранённой таблице время SVP 50% также меньше времени Random 50%: 4 696 против 5 409 секунд. Этот результат выглядит обнадёживающе, но преимущество по времени следует интерпретировать с оговоркой: перед строгим сравнением необходимо убедиться, что для всех вариантов одинаково учитывались этапы pipeline и границы измерения времени.

При бюджете 20% исходный SVP заметно уступил случайному отбору: Macro F1 составил 0,8522 против 0,9232, а Hit F1 — 0,6262 против 0,8210. Значит, при столь агрессивном сокращении данных использованное ранжирование в этом запуске не сохранило достаточно полезных примеров.

В последующем варианте SVP 20% + drop-inf из кандидатов исключались примеры с бесконечными оценками forgetting events. В сохранённом результате указаны Macro F1 = 0,9213, HitRate@5% = 84,54% и Hit F1 = 0,8143; исключено 11 246 примеров. По Macro F1 это существенно лучше исходного SVP 20%, но немного ниже Random 20% (0,9232). В журнале также фигурируют другой размер набора и отдельные детали разбиения, поэтому drop-inf не следует представлять как строго контролируемое сравнение, пока

не подтверждены одинаковые train/test split, бюджет и число оставленных примеров. Мы также не делаем предположений о причинах, по которым конкретные исключённые записи получили бесконечную оценку: имеющиеся результаты сами по себе этого не доказывают.

В целом Amazon-эксперимент показывает, что качество SVP зависит от бюджета и обработки оценок proxy. При 50% данных результат оказался близок к обучению на полном наборе; при 20% исходный метод сработал хуже случайного отбора, а дополнительное правило drop-inf заметно сократило этот разрыв.

4. Обсуждение

4.1. Что удалось проверить

На CIFAR-10 forgetting events превосходили случайный отбор при бюджетах 30% и 50% в имеющихся запусках. Entropy дала лучшее из наблюдаемых значений при бюджете 50%, но для этого метода есть только одна точка, поэтому вывод о поведении при разных бюджетах сделать нельзя.

На CIFAR-100 более длительное обучение proxy постепенно повышало качество target, но одновременно увеличивало общие затраты времени. Прирост между 50 и 100 эпохами оказался небольшим по сравнению с дополнительным временем обучения proxy. Это подчёркивает, что proxy не обязательно нужно доводить до максимально возможной длительности — подходящая длительность зависит от требуемого баланса качества и затрат.

На Amazon 50%-й вариант SVP сохранил Macro F1 близким к полному набору. Вариант с 20% данных выявил слабое место исходной схемы, а drop-inf улучшил результат. Это полезный пример того, что реализация критерия и обращение с неразрешимыми для proxy примерами могут влиять на конечное качество.

4.2. Почему важен выбор целевой модели

Использование WideResNet-28-10 в роли target было частью проверки переносимости метода: нас интересовало не только то, может ли маленькая proxy-модель отобрать данные для похожей по типу архитектуры, но и то, останется ли подвыборка полезной для более мощной целевой сети. Результаты CIFAR-10 показывают, что в исследованных конфигурациях отбор по forgetting events и entropy сохранял конкурентную точность на такой целевой модели. Однако без нескольких seed и полного набора одинаково настроенных сравнений это свидетельство работоспособности в конкретной постановке, а не универсальная гарантия.

4.3. Ограничения

1. Большинство результатов получено в одиночных запусках; вариативность по seed не измерялась.
2. Матрица корреляций Спирмена для CIFAR-100 не была надёжно получена из-за ошибки OpenMP. Поэтому гипотеза о согласованности ранжирований разных proxy-архитектур осталась без численного подтверждения.
3. На CIFAR-10 представлены только те сочетания метода и бюджета, для которых есть сохранённые результаты. Пропущенные точки не интерполировались.
4. Для CIFAR-100 нет сопоставимого baseline с обучением target на полном наборе при тех же условиях, поэтому количественное ускорение относительно полного обучения не заявляется.
5. Amazon-эксперимент использует данные и pipeline из отдельного проекта, а не исходный набор данных статьи. Это расширяет проверку метода, но не является точным воспроизведением оригинального Amazon/text-эксперимента.
6. В записях Amazon есть расхождения между размерами обучающей выборки в разных стадиях экспериментов. Вариант drop-inf также требует финальной проверки бюджета и разбиения перед строгим прямым сравнением.
7. Временные сравнения осмысленны только при одинаковых границах измерения: необходимо включать proxy, отбор и обучение target там, где эти этапы применимы.

5. Заключение

В работе реализованы и проверены отдельные сценарии отбора обучающих данных через proxy-модель на CIFAR-10, CIFAR-100 и данных Amazon. На CIFAR-10 forgetting events превзошли Random при бюджетах 30% и 50%, а Entropy при бюджете 50% показала 95,20% точности. Поскольку результаты не усреднялись по нескольким seed, эти различия требуют дополнительной проверки.

На CIFAR-100 увеличение длительности proxy с 25 до 100 эпох повысило точность target с 71,60% до 72,56%, а полное время — примерно с 105,8 до 119,8 минуты. Полученный прирост качества невелик по сравнению с дополнительными затратами, что демонстрирует практический компромисс при настройке SVP. Эксперимент с корреляцией Спирмена не дал пригодной матрицы, поэтому вывод о согласованности ранжирований разных архитектур остаётся открытым.

На Amazon вариант SVP с бюджетом 50% дал Macro F1 = 0,9254, близкий к значению полного набора 0,9282. При бюджете 20% исходный вариант заметно уступил случайному отбору, а дополнительная фильтрация drop-inf подняла Macro F1 до 0,9213. Последний результат перспективен, но требует сверки бюджета и разбиения с основным экспериментом.

Главный вывод состоит в том, что SVP может сохранять качество при умеренном сокращении данных, однако результат зависит от критерия отбора, бюджета и способа обработки оценок proxy. Проведённые эксперименты поддерживают идею метода в нескольких конкретных конфигурациях, но не дают оснований утверждать, что он одинаково эффективен для любых моделей и наборов данных.

Литература

1. Coleman, C., Yeh, C., Mussmann, S., Mirzasoleiman, B., Bailis, P., Liang, P., Leskovec, J., & Zaharia, M. (2020). Selection via Proxy: Efficient Data Selection for Deep Learning. International Conference on Learning Representations (ICLR). OpenReview.
2. Репозиторий экспериментов: AITH_Efficient_NN, hw2.
3. Оригинальный репозиторий SVP: stanford-futuredata/selection-via-proxy.